Przewidywanie cen akcji – metody uczenia maszynowego

Agnieszka Kęska

Spis treści

1 Wstęp **2**

2 Opis danych **2**

3 Charakterystyka czasowa danych **3**

4 Przetwarzanie danych **3**

5 Opis teoretyczny i wyniki zastosowanych metod **4**

5.1 Średnia krocząca 4
5.2 Wykładnicza średnia krocząca(EMA) 5
5.3 Regresja liniowa 6
5.4 Algorytm k-najbliższych sąsiadów 6
5.5 Lasy losowe 8
5.6 LSTM (Long Short-Term Memory) 9

6 Porównanie metod - wnioski **9**

7 Podsumowanie **11**

Przedmiot: Układy nieliniowe i uczenie maszynowe

1 Wstęp

Prognozowanie cen akcji jest jednym z istotnych problemów analizy finansowej oraz badań nad rynkami kapitałowymi. Ceny instrumentów finansowych tworzą szeregi czasowe o złożonej i nieliniowej strukturze, na które wpływają zarówno czynniki ekonomiczne, jak i elementy losowe. Z tego względu klasyczne metody analizy statystycznej często nie zapewniają wystarczającej dokładności w przewidywaniu przyszłych wartości. Przedstawione w niniejszej pracy metody mają charakter wyłącznie eksperymentalny i służą celom dydaktycznym, w związku z czym nie powinny być traktowane jako narzędzie wspomagające rzeczywiste decyzje inwestycyjne.

Celem projektu jest przewidywanie cen akcji spółek giełdowych oraz porównanie metod klasycznych, takich jak np. średnia krocząca, z metodami uczenia maszynowego dla tego zadania. Analizie poddano zarówno metody podstawowe, takie jak algorytm k-najbliższych sąsiadów, jak i bardziej zaawansowane podejścia oparte na sieciach neuronowych.

Badania zostały przeprowadzone dla firmy Google.

2 Opis danych

Dane giełdowe zostały pobrane z serwisu Yahoo Finance i obejmują okres od 2021 do 2025 roku. Zbiór danych zawiera łącznie 1229 obserwacji dla każdej spółki. Każdy rekord opisany jest następującymi zmiennymi:

- `Date` - data notowania.
- `Open` - cena otwarcia,
- `High` - najwyższa cena w danym dniu,
- `Low` - najniższa cena w danym dniu,
- `Close` - cena zamknięcia,
- `Volume` - wolumen obrotu,

Na podstawie kolumny `Date` wygenerowałąm dodatkowe zmienne:

- `Year` - rok, w którym przypada dana obserwacja,
- `Month` - miesiąc notowania,
- `Day` - dzień miesiąca,
- `Weekday` - dzień tygodnia, w którym miało miejsce notowanie (np. poniedziałek, wtorek),
- `DaySinceStart` - liczba dni, które upłynęły od pierwszej obserwacji.

3 Charakterystyka czasowa danych

Większość różnic pomiędzy kolejnymi datami wynosi 1 lub 3 dni, co odpowiada dniom roboczym oraz weekendom. Sporadycznie występują większe odstępy czasowe związane z dniami świątecznymi. Dane nie zawierają braków.Na poniższym wykresie można zauważyć trend rosnący cen akcji w analizowanym okresie.

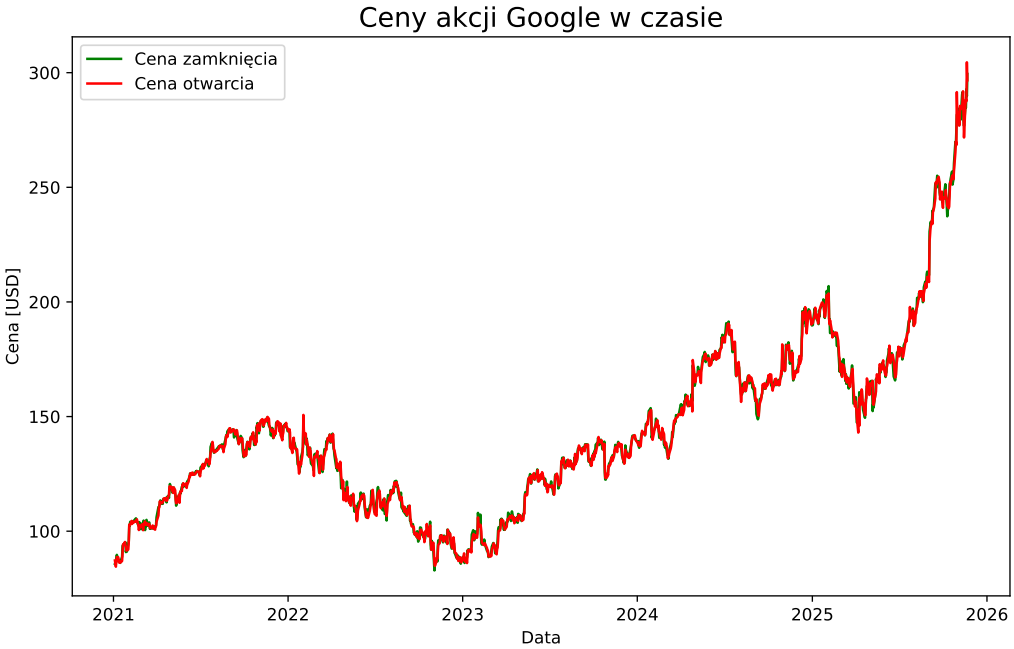

Rysunek 1: Ceny akcji Google w czasie

4 Przetwarzanie danych

Na etapie przetwarzania danych wykonałam następujące kroki:

- przekształcenie zmiennych do postaci numerycznej,
- skalowanie zmiennych w celu ujednolicenia ich zakresów,
- konstrukcję okien czasowych o długości 30 dni.
- podział danych na zbiory treningowy i testowy w proporcji 4:1, z zachowaniem kolejności czasowej obserwacji.

W celu uwzględnienia zależności czasowych w danych zastosowałam metodę okien czasowych. Dla każdej obserwacji utworzyłam wektor cech zawierający wartości zmiennych z ostatnich 30 dni notowań. Następnie jako wartość docelową przypisana została cen zamknięcia z dnia bezpośrednio następującego po analizowanym oknie czasowym.

5 Opis teoretyczny i wyniki zastosowanych metod

W tym projekcie zastosowano zarówno metody klasyczne, jak i algorytmy uczenia maszynowego, w celu porównania ich skuteczności w zadaniu prognozowania cen akcji. Wszystkie metody zostały dostosowane do analizy danych w postaci szeregów czasowych.

5.1 Średnia krocząca

Średnia krocząca jest jedną z najprostszych i najczęściej stosowanych metod analizy szeregów czasowych. Polega ona na obliczaniu średniej arytmetycznej z ostatnich n obserwacji, co pozwala na wygładzenie krótkookresowych wahań oraz uwydatnienie trendu. Dla szeregu czasowego x_t średnia krocząca rzędu n dana jest wzorem:

$$MA_t = \frac{1}{n} \sum_{i=0}^{n-1} x_{t-i}.$$

Metoda ta nie wymaga uczenia modelu ani estymacji parametrów i stanowi punkt odniesienia dla bardziej zaawansowanych algorytmów. Jej ograniczeniem jest brak zdolności do modelowania złożonych zależności nieliniowych oraz silne uzależnienie wyników od długości okna czasowego.

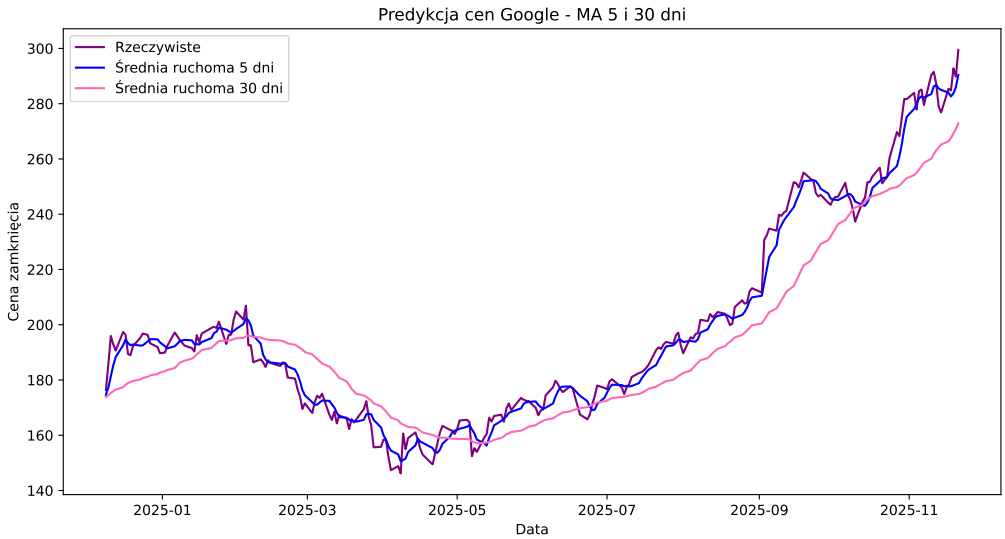

Rysunek 2: Predykcja cen Google - MA 5 i 30 dni

5.2 Wykładnicza średnia krocząca(EMA)

Wykładnicza średnia krocząca (EMA, *Exponential Moving Average*) stanowi rozszerzenie klasycznej średniej kroczącej, w którym większą wagę przypisuje się nowszym obserwacjom. Dzięki temu metoda ta szybciej reaguje na zmiany zachodzące w szeregu czasowym, jednocześnie zachowując właściwości wygładzające. Dla szeregu czasowego x_t wykładnicza średnia krocząca dana jest wzorem:

$$EMA_t = \alpha x_t + (1 - \alpha) EMA_{t-1},$$

gdzie $\alpha \in (0, 1)$ jest współczynnikiem wygładzania, określającym wpływ bieżącej obserwacji na wartość średniej.W przeprowadzonych eksperymentach wykładnicze średnie kroczące zostały obliczone z wykorzystaniem domyślnej parametryzacji biblioteki `pandas`, w której współczynnik wygładzania α wyznaczany jest na podstawie długości okna czasowego n zgodnie ze wzorem

$$\alpha = \frac{2}{n+1}.$$

Podobnie jak w przypadku klasycznej średniej kroczącej, metoda ta nie wymaga procesu uczenia modelu ani estymacji złożonych parametrów. Jej zaletą jest większa czułość na bieżące zmiany cen, natomiast ograniczeniem pozostaje brak możliwości modelowania złożonych zależności nieliniowych.

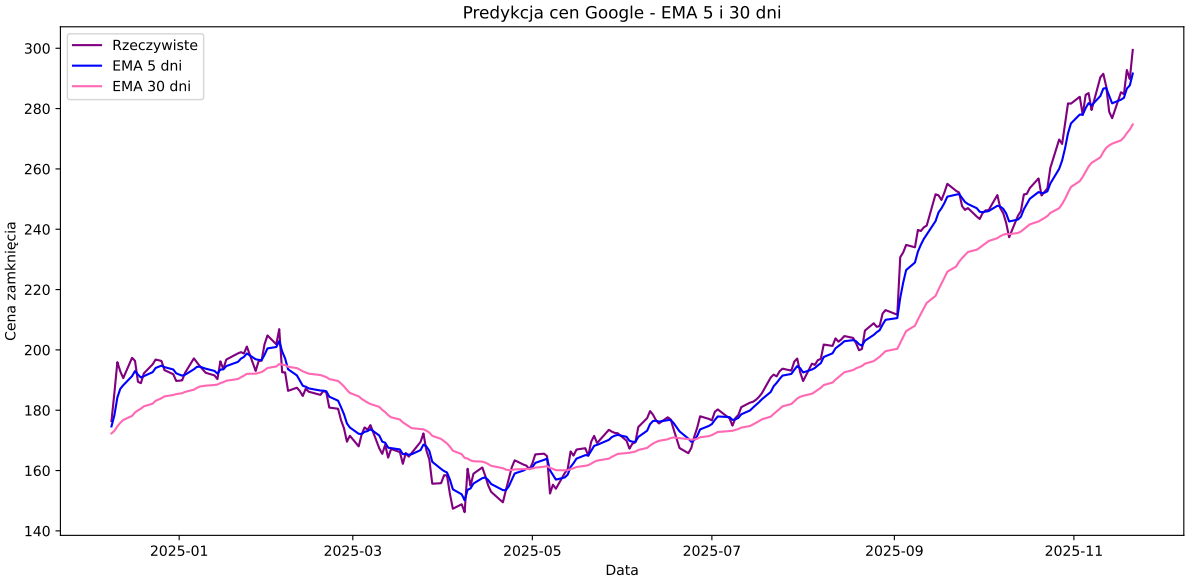

Rysunek 3: Predykcja cen Google - EMA 5 i 30 dni

5.3 Regresja liniowa

Regresja liniowa jest jednym z najprostszych i najbardziej klasycznych modeli statystycznych stosowanych w prognozowaniu wartości szeregów czasowych. Model zakłada, że zależność między zmiennymi objaśniającymi, a zmienną objaśnianą jest liniowa. W przypadku szeregów czasowych cen akcji regresja liniowa stara się dopasować prostą, która najlepiej przewiduje cenę zamknięcia na podstawie wybranych cech wejściowych, takich jak wartości z poprzednich dni czy dodatkowe cechy czasowe.

Dla zbioru danych $\{(X_i, y_i)\}_{i=1}^{N}$ model liniowy przyjmuje postać:

$$y_i = \omega_0 + \omega_1 X_{i1} + \omega_2 X_{i2} + \cdots + \omega_p X_{ip} + \varepsilon_i,$$

gdzie $\omega_0, \ldots, \omega_p$ są parametrami regresji, a ε_i oznacza składnik losowy. Parametry te estymuje się zazwyczaj metodą najmniejszych kwadratów, minimalizując sumę kwadratów różnic pomiędzy wartościami rzeczywistymi a przewidywanymi.

Zaletą regresji liniowej jest prostota interpretacji i brak potrzeby stosowania skomplikowanego procesu uczenia. Jej głównym ograniczeniem jest niemożność uchwycenia nieliniowych zależności i skomplikowanych interakcji między cechami, które mogą występować w danych finansowych.

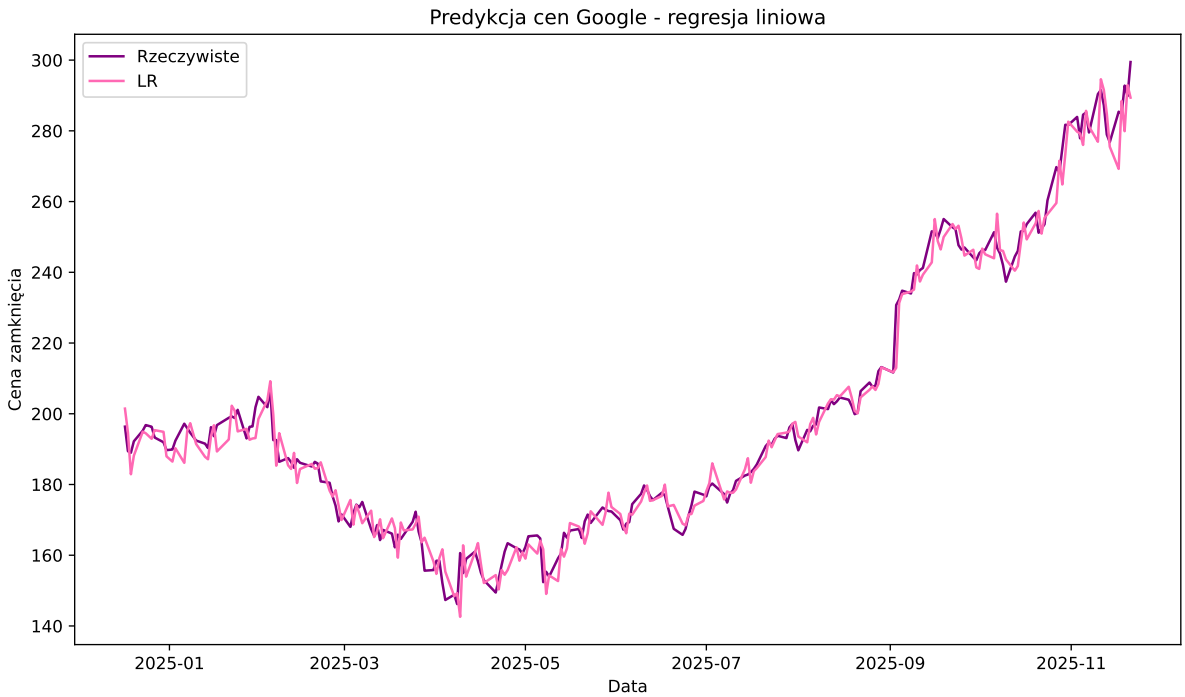

Rysunek 4: Predykcja cen Google - Regresja liniowa

5.4 Algorytm k-najbliższych sąsiadów

Algorytm k-najbliższych sąsiadów jest metodą uczenia maszynowego opartą na podobieństwie obserwacji. W zadaniu regresji przewidywana wartość zmiennej objaśnianej obliczana jest jako średnia wartości k najbliższych sąsiadów w przestrzeni cech. Odległość pomiędzy obserwacjami najczęściej mierzona jest za pomocą metryki euklidesowej.

W klasycznej postaci algorytm KNN nie uwzględnia struktury czasowej danych. W niniejszym projekcie został on jednak dostosowany do analizy szeregów czasowych poprzez

zastosowanie okna czasowego. Wektor cech dla danego dnia tworzony jest na podstawie cen zamknięcia z kilku poprzednich dni, co pozwala algorytmowi wykorzystywać informacje historyczne.

Predykcja wykonywana jest w sposób rekurencyjny, co oznacza, że przewidywane wartości dla kolejnych dni są wykorzystywane jako dane wejściowe do następnych prognoz.

W celu dobrania optymalnych parametrów przeprowadzono wyszukiwanie siatki (*grid search*) dla następujących wartości:

- liczba sąsiadów: $n_neighbors = [3, 5, 7, 9, 11]$,
- wagi: `weights` = ['uniform', 'distance'],
- metryka odległości: $p = [1, 2]$.

Najlepsze parametry uzyskane podczas optymalizacji to:

$$n_neighbors = 11, \quad p = 1, \quad \text{weights} = \text{'distance'}.$$

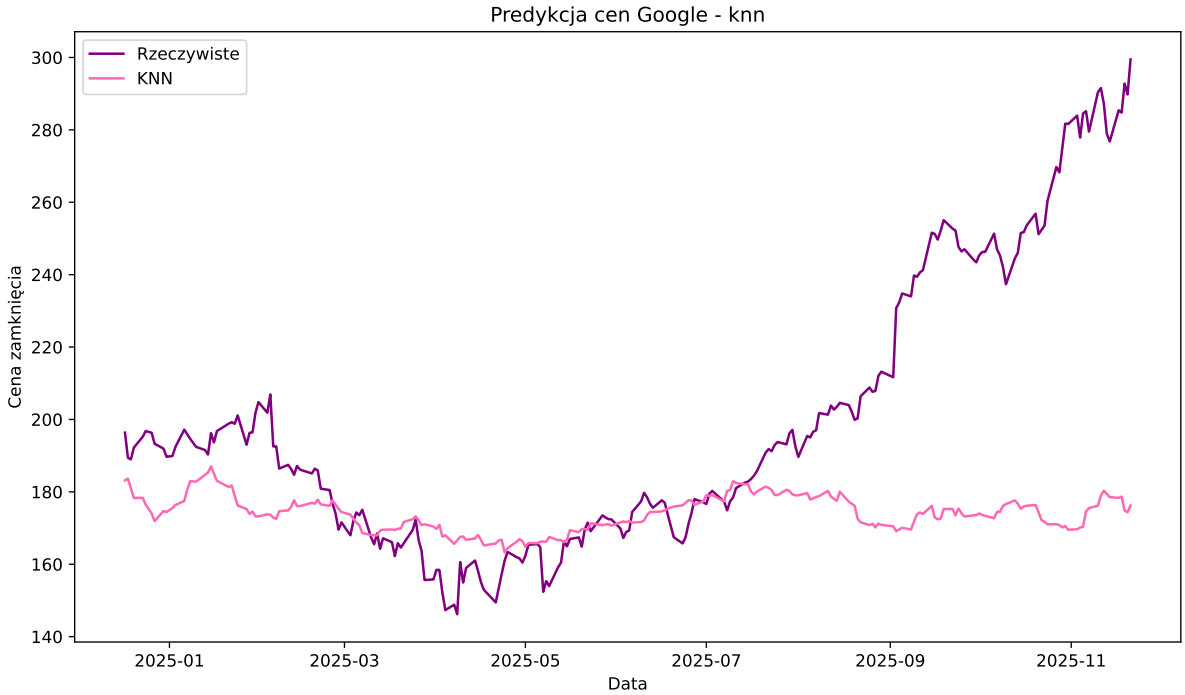

Rysunek 5: Predykcja cen Google - KNN

5.5 Lasy losowe

Random Forest jest zespołową metodą uczenia maszynowego należącą do grupy algorytmów opartych na drzewach decyzyjnych. Model tworzy wiele drzew regresyjnych, z których każde jest trenowane na losowej podpróbce danych oraz losowym podzbiorze cech. Końcowa prognoza uzyskiwana jest jako średnia przewidywań wszystkich drzew w lesie, co pozwala zmniejszyć wariancję i poprawić stabilność prognoz w porównaniu do pojedynczego drzewa decyzyjnego.

Dla zbioru danych $\{(X_i, y_i)\}_{i=1}^{N}$ każdy estymator drzewa regresyjnego tworzy model:

$$y_i^{(t)} = f_t(X_i) + \varepsilon_i^{(t)},$$

gdzie f_t oznacza funkcję dopasowaną przez t-te drzewo w lesie, a $\varepsilon_i^{(t)}$ jest składnikiem losowym. Ostateczna prognoza modelu Random Forest wyznaczana jest jako średnia przewidywań wszystkich T drzew:

$$\hat{y}_i = \frac{1}{T} \sum_{t=1}^{T} y_i^{(t)}.$$

Zaletą lasów losowych jest zdolność uchwycenia złożonych, nieliniowych zależności w danych oraz odporność na przeuczenie w porównaniu do pojedynczych drzew decyzyjnych. Głównym ograniczeniem jest mniejsza interpretowalność w porównaniu do prostych modeli, takich jak regresja liniowa.

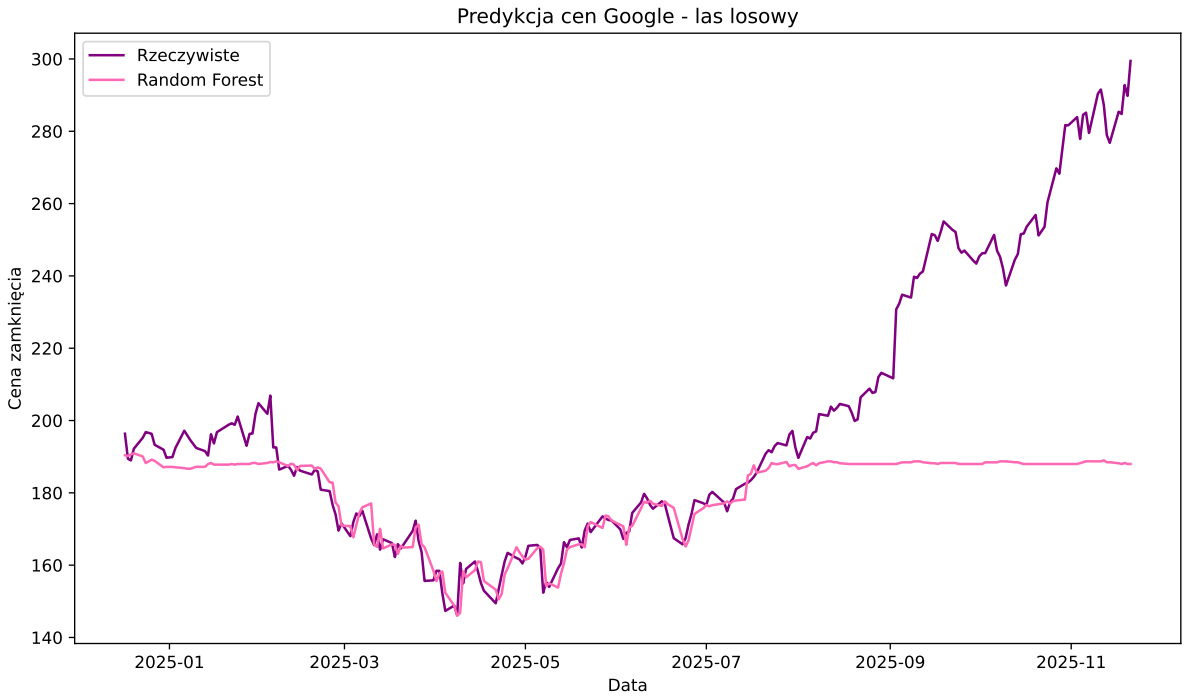

Rysunek 6: Predykcja cen Google - las losowy

5.6 LSTM (Long Short-Term Memory)

LSTM (Long Short-Term Memory) jest rodzajem rekurencyjnej sieci neuronowej (RNN) zaprojektowanej do modelowania sekwencji danych i uchwycenia zależności długookresowych w szeregach czasowych. W przeciwieństwie do standardowych RNN, LSTM posiada specjalne jednostki pamięci, które umożliwiają selektywne zapamiętywanie lub zapominanie informacji, co pozwala na efektywne modelowanie złożonych, nieliniowych zależności w danych sekwencyjnych.

Mechanizm działania LSTM opiera się na trzech bramkach: zapominania, wejścia i wyjścia, które kontrolują przepływ informacji w komórce pamięci oraz aktualizację stanu ukrytego.

LSTM jest szczególnie przydatny w prognozowaniu szeregów czasowych finansowych, ponieważ potrafi uchwycić zarówno krótkookresowe wahania, jak i długoterminowe trendy. Ograniczeniem modelu jest większa złożoność obliczeniowa oraz potrzeba odpowiedniego doboru parametrów sieci, co może wymagać znacznych zasobów danych i mocy obliczeniowej.

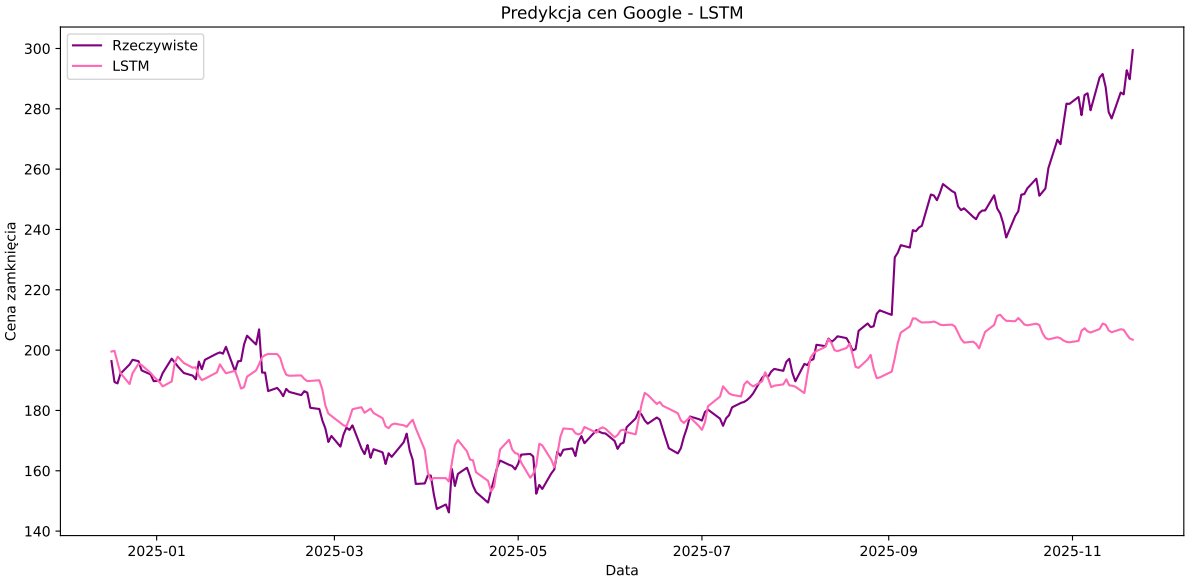

Rysunek 7: Predykcja cen Google - LSTM

6 Porównanie metod - wnioski

Na podstawie przeprowadzonych eksperymentów i wizualnej analizy wykresów predykcji możemy zauważyć wyraźne różnice w skuteczności poszczególnych modeli. Modele oparte na metodach klasycznych, takie jak średnia krocząca (MA) oraz wykładnicza średnia krocząca (EMA), radzą sobie najlepiej w krótkim horyzoncie czasowym, szczególnie przy zastosowaniu krótszych okien (np. 5-dniowych). Dłuższe okna, takie jak 30-dniowe, wykazywały mniejszą zdolność do odzwierciedlenia szybkich zmian cen.

Regresja liniowa, jako najprostszy model uczenia maszynowego, dobrze uchwyciła trend w danych i była w stanie poprawnie prognozować najwyższe wartości zamknięcia pod koniec analizowanego okresu.

Modele bardziej zaawansowane, takie jak k-nearest neighbors (KNN) oraz Random Forest, radziły sobie stosunkowo słabo, zwłaszcza w końcowej części szeregu czasowego,

gdy ceny zamknięcia gwałtownie wzrosły w porównaniu do zakresu cen, na którym były trenowane. Podobnie sieć LSTM nie odtworzyła prawidłowo końcowego trendu i nie przewidziała najwyższych wartości.

Ogólnie można stwierdzić, że w przypadku krótkoterminowych prognoz cen akcji metody klasyczne są dobre, natomiast w przypadku zmiennych, gwałtownie rosnących wartości modele uczenia maszynowego wymagają dodatkowej adaptacji, większej ilości danych lub bardziej zaawansowanej konfiguracji, aby poprawnie uchwycić ekstremalne wartości.

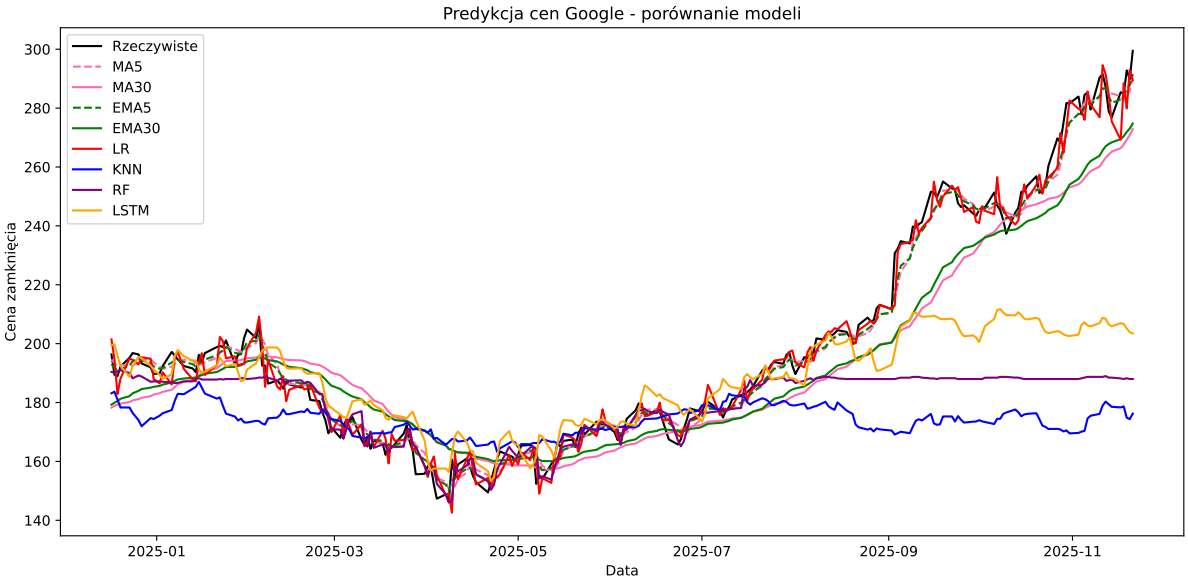

Rysunek 8: Porównanie modeli prognozowania cen akcji Google

Miary oceny dokładności modeli:

Do oceny jakości prognoz wykorzystano trzy podstawowe miary błędu: MSE, RMSE i MAE.

- **MSE (Mean Squared Error, średni błąd kwadratowy)**:

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

  mierzy średnią wartość kwadratów różnic między wartościami rzeczywistymi y_i a przewidywanymi $\hat{y}_i$.

- **RMSE (Root Mean Squared Error, pierwiastek średniego błędu kwadratowego)**:

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}$$

- **MAE (Mean Absolute Error, średni błąd bezwzględny)**:

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

W poniższej tabeli widać, że modele MA5 i LR mają najniższe wartości RMSE i MAE, co oznacza, że przewidują najdokładniej, natomiast modele KNN i RF charakteryzują się dużymi błędami.

model	RMSE	MSE	MAE
MA5	4.43	19.64	3.50
MA30	14.18	201.04	11.73
EMA5	12.90	13.11	2.85
EMA30	14.18	166.32	10.73
LR	4.64	21.54	3.49
KNN	45.21	2043.56	29.40
RF	37.12	1377.69	21.60
LSTM	28.76	826.98	17.71

7 Podsumowanie

Przeprowadzona analiza porównawcza wykazała, że metody klasyczne, takie jak średnia krocząca i wykładnicza średnia krocząca, dobrze odwzorowują krótkoterminowe zmiany cen i efektywnie wychwytują trend. Regresja liniowa spośród modeli uczenia maszynowego radziła sobie najlepiej, uchwyciła trend i prawidłowo przewidziała najwyższe ceny zamknięcia. Z kolei KNN, Random Forest oraz LSTM miały trudności w prognozowaniu gwałtownych wzrostów cen pod koniec analizowanego okresu, co wynikało z ograniczonego zakresu danych treningowych.